

--数据科学导论大作业--

# 解构对话：一份微信聊天记录的深度剖析

结合 Python 数据科学与 AI 洞察，揭示近万条消息背后的关系图谱

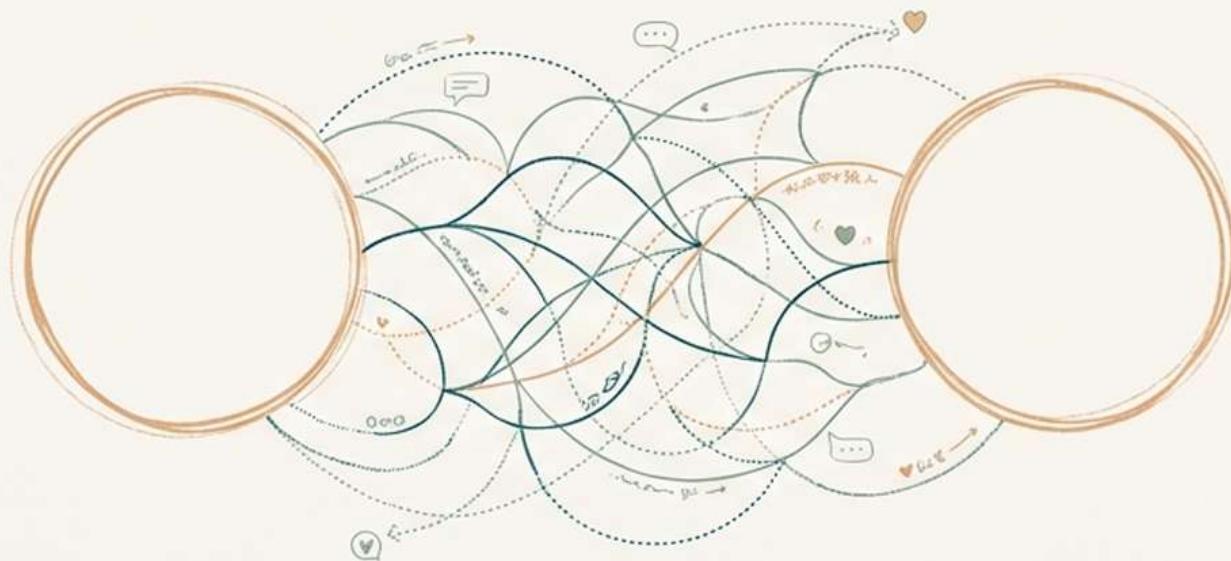
吴晨曦 10242150443

# 缘起：一份定制的“关系年度报告”



通用平台年度回顾

每年，各大平台都会为我们生成年度报告。我们能否为自己最重要的一段对话，也生成一份独特的“关系报告”？



独特的二人“关系报告”

# 分析蓝图：从数据到洞察的六步法

- 1 **数据准备**  
从海量记录中提取结构化信息。
- 2 **基本画像**  
勾勒对话的宏观轮廓。
- 3 **活跃节律**  
探寻沟通的时间模式。
- 4 **核心话题**  
解读我们最关心的事。
- 5 **情感动力学**  
量化感受的起伏与温度。
- 6 **AI 综合研判**  
生成最终的定性洞察报告。

# 0.数据导出——EchoTrace开源工具

- 原理：电脑版微信的聊天记录存储在本地的 SQLite 数据库中(加密)。密钥通常存储在微信运行时的内存中。
- 方法：通过开源工具（如 EchoTrace）解密、配置并以指定格式导出

[echotrace/docs/beginner\\_guide.md at main · ycccccyy/echotrace](https://github.com/ycccccyy/echotrace/blob/main/docs/beginner_guide.md)



EchoTrace

设置

测试连接 保存配置

微信数据库配置  
配置解密密钥和数据库路径

解密密钥  
请输入64位十六进制密钥  
.....

数据库根目录  
自动检测或手动选择xwechat\_files目录

自动检测 手动选择

账号wxid  
已保存wxid，可手动修改或重新扫描

扫描wxid

v2.2.3

db\_storage

文件夹 > F:\ > xwechat\_files >

# 1. 数据预处理

一切分析始于干净、可靠的数据。

## 数据源

使用 EchoTrace 工具安全导出本地微信聊天记录为 JSON 格式。

## 技术栈

核心使用 Python 及 Pandas (数据处理) ,  
Matplotlib/Seaborn (可视化) , Jieba (分词) ,  
Transformers (情感分析) 等库。

## 关键处理

将 9,961 条原始消息转化为结构化的 DataFrame,  
提取时间、发送者、消息类型等关键特征，并进行数  
据清洗。(转换时间戳、提取特征、删除空数据等)

```
],  
{  
    "localId": 1646,  
    "createTime": 1748786290,  
    "formattedTime": "2025-06-01 21:58:10",  
    "type": "文本消息",  
    "localType": 1,  
    "content": "哈哈哈哈哈哈啊哈哈哈哈",  
    "isSend": 0,  
    "senderUsername": "wxid_2gbxgakagb9422",  
    "senderDisplayName": "myfriend",  
    "source": "<msgsource>\n      <sec_msg_node>\n",  
},  
{  
    "localId": 1645,  
    "createTime": 1748786305,  
    "formattedTime": "2025-06-01 21:58:25",  
    "type": "文本消息",  
    "localType": 1,  
    "content": "试试别的软件",  
    "isSend": 0,  
    "senderUsername": "wxid_2gbxgakagb9422",  
    "senderDisplayName": "myfriend",  
    "source": "<msgsource>\n      <sec_msg_node>\n",  
},  
]
```

## 2. 基本画像

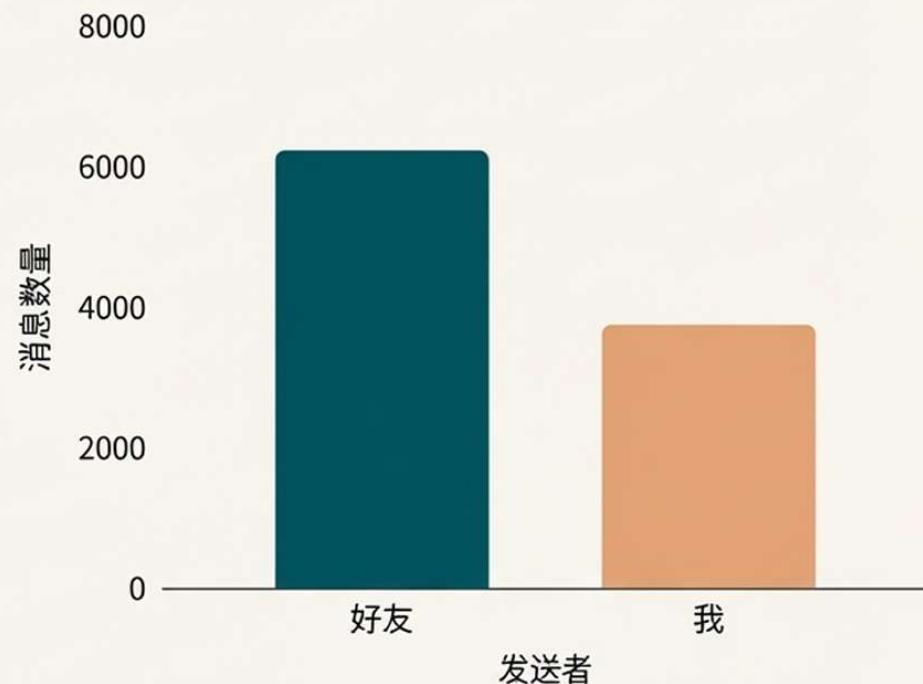
对话画像：谁在主导这场对话？ `sender_counts = chat_df['sender'].value_counts()`

数据呈现清晰的“分享-回应”动态，而非均等的对话量。

总消息数：9,961 条

好友：6,204 条（62.3%） - 主要的分享者与话题发起者。

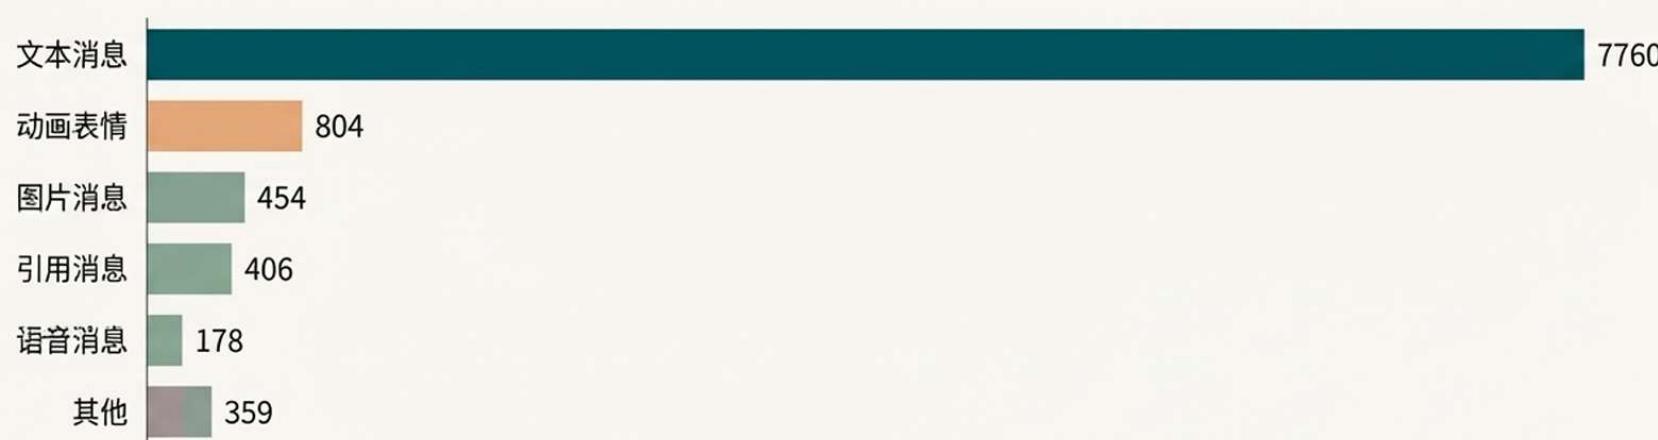
我：3,757 条（37.7%） - 积极的倾听者与回应者。



## 2. 基本画像

沟通方式：不止于文字

```
message_type_counts = chat_df['message_type'].value_counts()
```



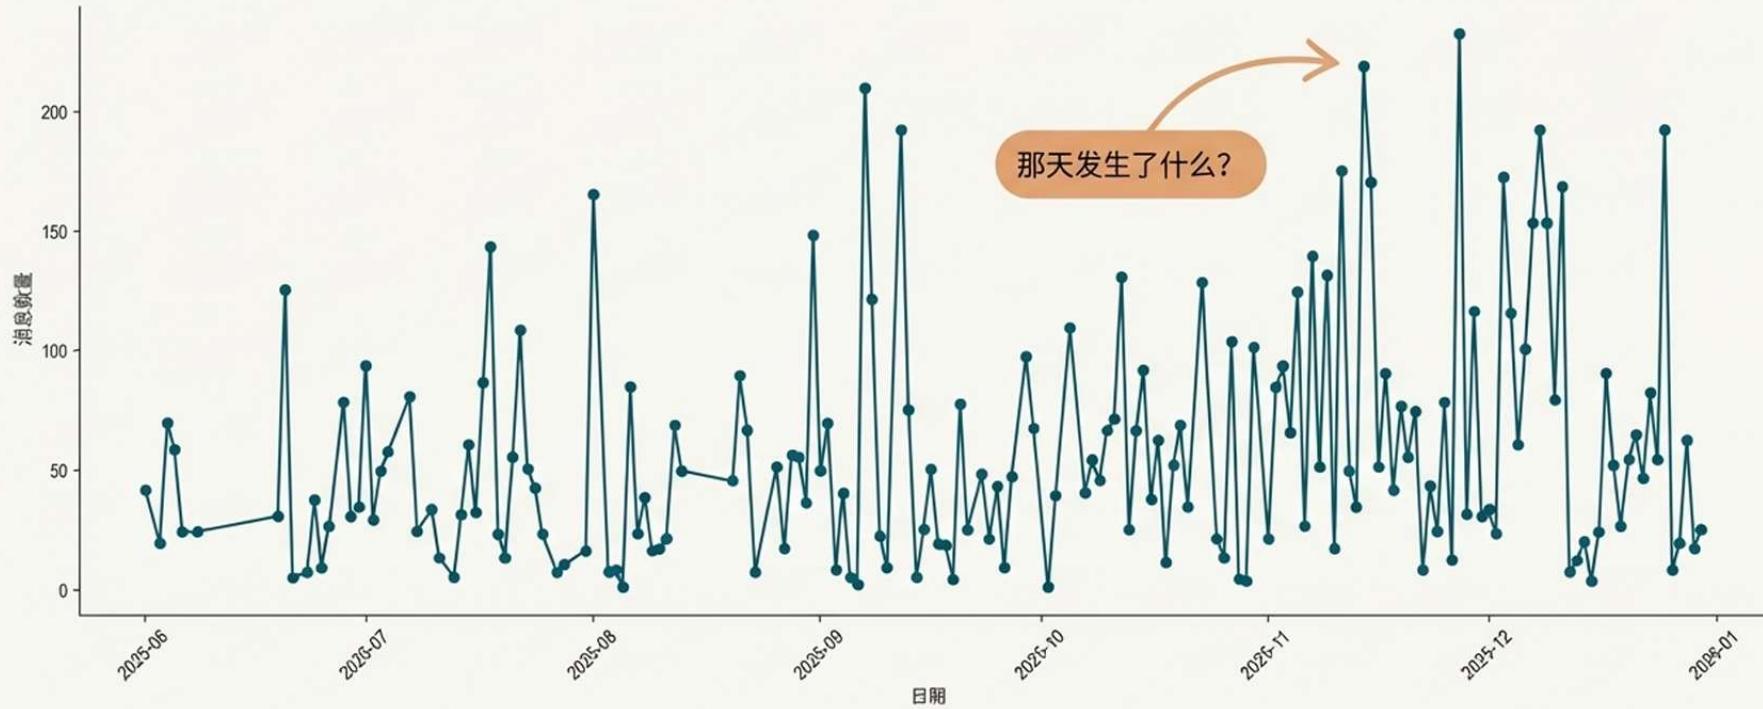
- ⌚ 文本消息 (78%) : 沟通的主体，是深度分析的基础。
- 😊 动画表情 (8%) : 情感的快捷方式，传递即时感受。
- 🖼️ 图片消息 (4.6%) : 分享生活瞬间，连接彼此世界。
- ⌚ 其他: 引用、语音、链接等消息类型进一步丰富了交流的维度。

### 3. 活跃节律

#### 沟通的潮汐：每日消息量趋势

`daily_trend = chat_df.groupby('date').size()`

沟通强度并非一成不变，而是呈现显著的“峰谷”波动。这与双方的现实生活事件（如假期、工作繁忙期、共同经历）高度相关。

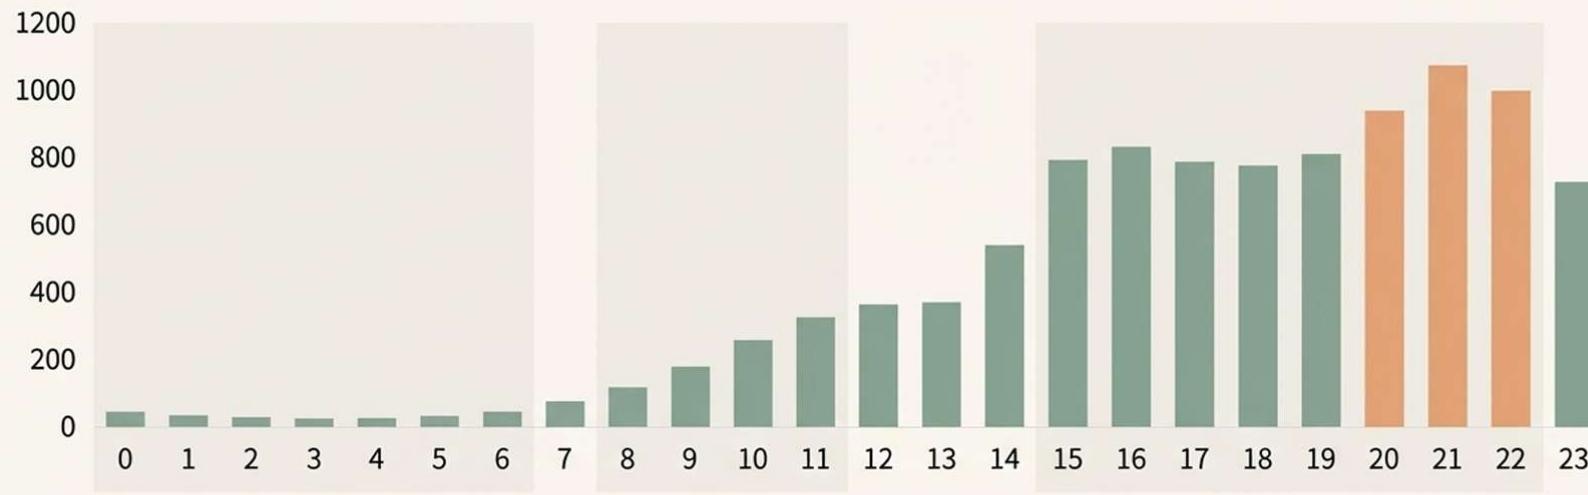


### 3. 活跃节律

#### 我们的“聊天时区”：每小时活跃度解密

`hourly_activity = chat_df.groupby('hour').size()`

对话拥有非常清晰的日内节律，集中在下午和夜晚，晚间 9-10 点是沟通的黄金时段。



凌晨 (0-7点)：静默区，符合普遍作息规律。

上午 (8-12点)：  
缓慢启动。

下午至夜晚 (15-23点)：核心活跃区，反映了学生或上班族在日间的空闲时段及下班/下课后的放松时段进行集中沟通的习惯。

# 4.核心话题

- stop\_word机制

高频词汇揭示了对话的核心：紧密围绕“日常生活”、“个人感受”和“共同经历”展开。词汇的“去事件化”与“情感化”特征显著，表明对话价值在于持续的情感确认与联结。

- 结巴分词



- 词云展示

## 生活日常

哈哈、吃、同学、  
老师、学校、回家

## 情感表达

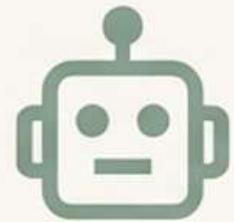
感觉、真的、喜欢、  
开心、没事

## 时间与状态

今天、现在、晚上、  
回来

## 5. 情感分析

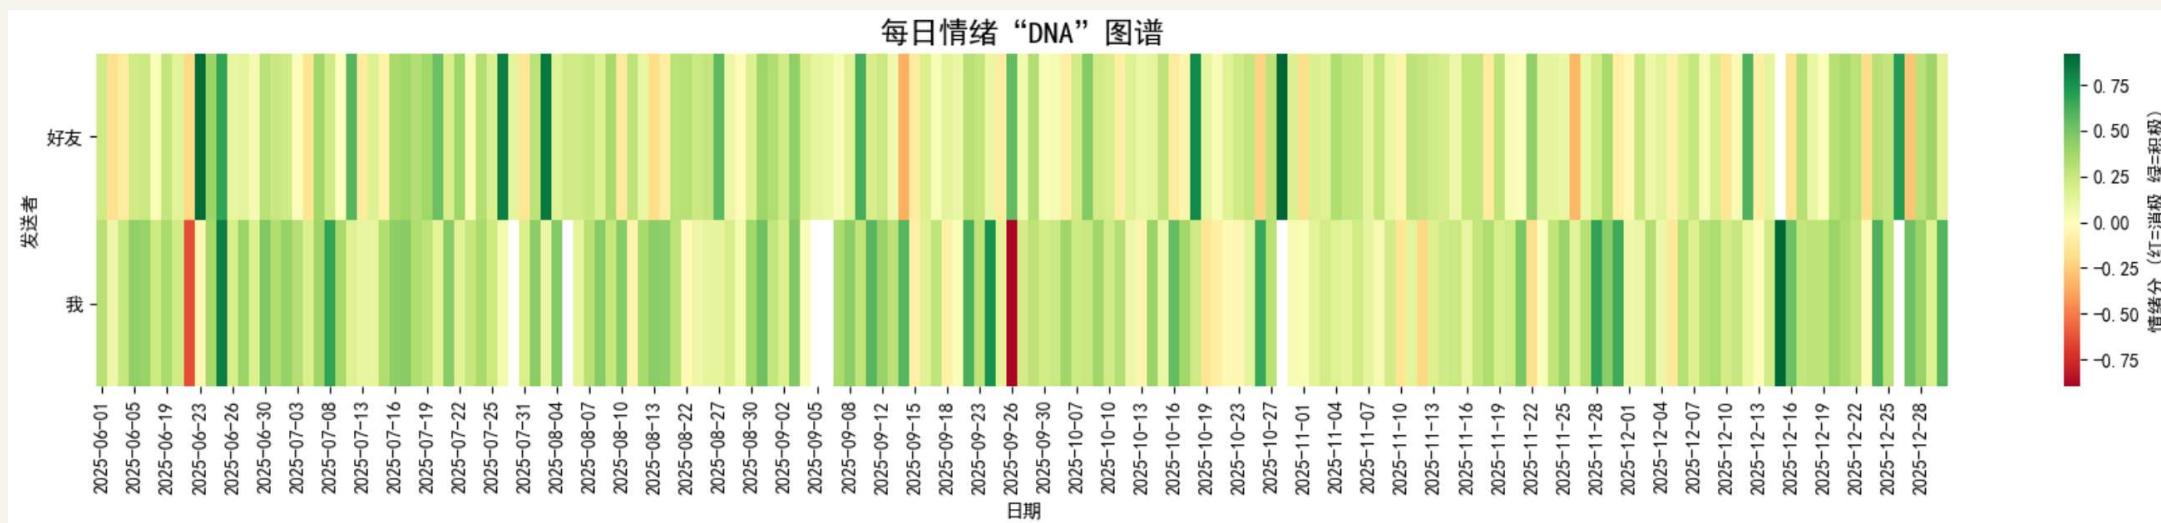
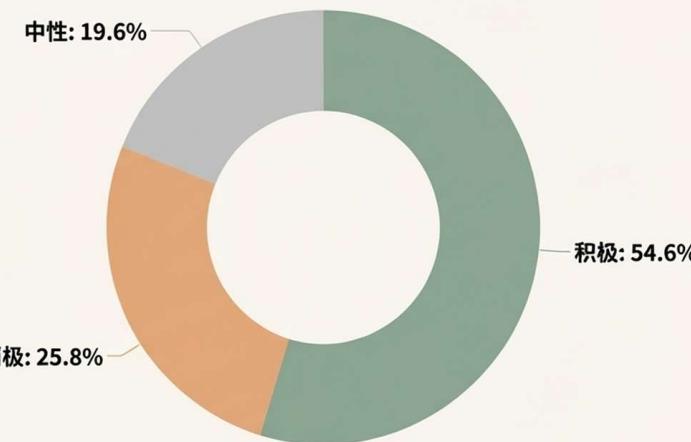
- 基于 Transformer 架构、利用电商语料微调的二分类情感分析系统
- RoBERTa (Robustly optimized BERT approach)
  - BERT 的进阶版
  - Transformer 架构：利用自注意力机制 (Self-Attention) 捕捉文本中字与字之间的上下文关系
- 后处理
  - 中性区间过滤： $0.4-0.6 \rightarrow$  归为中性
  - 概率线性映射： $[0,1] \rightarrow [-1,1]$



Transformers

# 5. 情感分析

- 情绪分布饼图
- 每日情绪DNA
- 情绪波动曲线



# 情绪波动曲线：追踪高光与低谷时刻

通过量化每日情绪，我们可以精准定位关系中的“开心巅峰”与“情绪低谷”，并回溯其背后事件。



## Case Study

日期

2025-06-21，被标记为气氛最压抑的一天（平均分: -0.35）。

触发消息



真的笑鼠我了

发送者

分析

这句话在人类语境中表达的是极度的幽默和开心，但模型因未能理解网络俚语“笑鼠”的正面含义，将其误判为强烈的负面情绪。这个“错误”恰恰是理解模型局限性的一个绝佳案例。

# 6.AI分析报告

- 准备文本内容进行分词
- 构建prompt
- 调用API (deepseek)

```
prompt = f"""
请根据以下聊天数据摘要，生成一份简短、深刻的中文分析报告。报告应包括：
1. 对整体聊天风格和氛围的总结。
2. 对主要参与者的沟通模式的简要分析。
3. 基于高频词汇，推断出他们可能的核心话题或关系特点。
4. 提出一两个有趣的观察或结论。

**数据摘要：**
- **时间跨度**: {duration_days} 天
- **总消息数**: {total_messages} 条
- **参与者消息分布**:
....
```

## 聊天数据分析报告

### 1. 整体聊天风格与氛围

在长达212天的持续互动中，两位参与者共交换了近万条消息，形成了**高频、紧密且高度日常化**的沟通模式。聊天氛围整体呈现出**轻松、信任、生活化**的特点，双方建立了稳定的分享习惯。好友在消息数量上占据主导（62.3%），显示出更强的表达欲和分享主动性，而“我”则扮演了积极的倾听与回应者角色。这种不对等的消息量并未破坏平衡，反而可能暗示了一种默契的**互补关系**。

### 2. 主要参与者沟通模式分析

- 好友（主导分享者）**：其沟通模式具有**高频率、细节丰富、情感外露**的特点。占据六成以上的消息量，表明其习惯于将日常琐事、即时情绪与想法进行持续性输出。这种模式可能源于强烈的表达需求、对关系的信任，或希望通过分享来维系亲密感。
- “我”（积极回应者）：虽然消息量较少，但近38%的占比在长期对话中仍属高度参与。其模式更偏向**倾听、承接话题、提供情感反馈或实用建议**。这种“**回应型**”沟通维系了对话的流动性，并可能为好友的分享提供了稳定的情感容器。

### 3. 高频词汇揭示的核心话题与关系特点

从高频词分析，对话核心紧密围绕**两人共同的现实生活与情感世界**：

- 生活实景**（“今天”、“吃”、“哈哈”、“回家”、“睡觉”）：词汇极具日常性与即时性，表明聊天是彼此**生活节奏同步与陪伴**的重要方式。分享三餐、作息、日常趣事（“哈哈”）构成了关系的基底。
- 关系指向**（“你”、“我”、“宝宝”）：人称代词的高频使用凸显对话的**直接性与互动性**。“宝宝”一词的出现（即便频率不高）是重要信号，可能暗示着**亲密昵称、恋人关系或深厚的情感依恋**，这是定义关系性质的关键词。
- 情感与状态**（“感觉”、“现在”）：注重分享当下心境与感受，沟通具有**情感流动与状态同步**的特点，而非单纯事务性交流。

**核心推断**：两人很可能处于**亲密关系（如恋人或挚友）**\*\*中，聊天主要功能是维系日常情感连接、分享生活实感、提供陪伴\*\*。关系已深度融入彼此日常生活。

### 4. 有趣的观察与结论

- “分享即陪伴”的非对称平衡**：尽管消息量有显著差距（62.3% vs 37.7%），但这并未导致关系失衡，反而可能形成了一种**稳定的“倾诉-承接”动态**。好友通过高频分享获得陪伴感与情感释放，“我”则通过积极回应获得参与感与关系满足。这挑战了“消息量均等才健康”的简单假设，体现了关系模式的多样性。
- 词汇的“去事件化”与“情感化”**：Top词汇中罕见具体事件、人物或宏大话题，几乎全部聚焦于**个人化的瞬间感受与微观生活**。这表明，对话的核心价值不在于信息交换，而在于**持续的情感确认与联结**。他们的关系可能更依赖于这种日常“微循环”来滋养，而非依赖重大事件或深度讨论。

**总结**：这是一段深度嵌入日常、以情感陪伴为核心功能的亲密对话。其生命力不在于话题的波澜壮阔，而在于日复一日的分享与回应所构筑的稳定感和亲密感。

## 结论：一份数据驱动的“关系说明书”

本项目成功将海量、非结构化的聊天数据，转化为一幅关于沟通模式、互动节律与情感动态的结构化、可解读的洞察图谱。

---

数据分析不仅是技术工具，更提供了一种全新的视角，帮助我们回顾与理解自己的人际互动，珍视那些在日常交流中悄然流逝的情感与时光。

谢谢观看！